

Entendendo as Métricas

Modelos de Machine Learning

PROJETO INTEGRADOR 3 - Projeto 2 – Recursos Humanos

Prof. Dr. Dilermando Piva Jr.

Acurácia (Accuracy)

A **acurácia** é uma métrica que mede a proporção de previsões corretas feitas pelo modelo em relação ao total de amostras testadas. Ela responde à pergunta:

> **"Qual a porcentagem de classificações corretas feitas pelo modelo?"**

Fórmula da Acurácia

$$\text{Accuracy} = \frac{\text{Número de previsões corretas}}{\text{Número total de amostras}}$$

Ou, de forma mais detalhada:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Onde:

- **TP (True Positives)** = Verdadeiros Positivos (classificações corretas como positivas).
- **TN (True Negatives)** = Verdadeiros Negativos (classificações corretas como negativas).
- **FP (False Positives)** = Falsos Positivos (erros onde o modelo previu positivo, mas era negativo).
- **FN (False Negatives)** = Falsos Negativos (erros onde o modelo previu negativo, mas era positivo).

1 Precision (Precisão)

A **precisão** mede a qualidade das previsões positivas do modelo. Ela responde à pergunta:

> **"Das instâncias que o modelo classificou como positivas, quantas realmente são positivas?"**

Fórmula da Precisão

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Onde:

- **TP (True Positives)** = Verdadeiros Positivos (acertos nas previsões positivas).
- **FP (False Positives)** = Falsos Positivos (erros onde o modelo previu positivo, mas era negativo).

Interpretação

- Quanto maior a precisão, menos falsos positivos o modelo gera.
- Se a precisão for alta, significa que o modelo raramente prevê positivo erroneamente.
- Aplicável quando erros do tipo falso positivo são problemáticos, como em diagnósticos médicos (um falso positivo pode gerar tratamentos desnecessários).

2 Recall (Revocação ou Sensibilidade)

A **revocação** mede a capacidade do modelo de encontrar todas as instâncias positivas. Ela responde à pergunta:

> **"Das instâncias realmente positivas, quantas foram corretamente identificadas?"**

Fórmula do Recall

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Onde:

- **TP (True Positives)** = Verdadeiros Positivos.
- **FN (False Negatives)** = Falsos Negativos (erros onde o modelo não detectou um caso positivo).

Interpretação

- Quanto maior o recall, menos falsos negativos o modelo comete.
- Um alto recall significa que o modelo consegue detectar bem os casos positivos, mesmo que gere alguns falsos positivos.
- Aplicável quando perder uma detecção positiva é crítico, como em detecção de fraudes ou câncer (falsos negativos podem ser desastrosos).

3 F1-Score

O **F1-score** é a média harmônica entre precisão e recall, fornecendo uma única métrica que equilibra os dois aspectos.

Fórmula do F1-Score

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Interpretação

- O F1-score equilibra precisão e recall, sendo útil quando há um desbalanceamento de classes.
- Se **precision** e **recall** forem igualmente importantes, o F1-score é uma métrica ideal.
- Valores próximos de 1 indicam um bom desempenho.

4 Support

O **support** indica a quantidade de exemplos reais de cada classe no conjunto de dados.

Interpretação

- Ajuda a entender o peso de cada classe na avaliação.
- Se uma classe tiver um número muito baixo de amostras, a métrica pode não ser confiável.
- Modelos que funcionam bem para classes majoritárias, mas não para minoritárias, podem ser identificados através dessa métrica.

Resumo das Métricas

Métrica	Fórmula	Indicação de uso
Acurácia (Accuracy)	$\frac{TP+TN}{TP+TN+FP+FN}$	Boa para classes balanceadas, mas problemática para desbalanceadas.
Precisão (Precision)	$\frac{TP}{TP+FP}$	Boa quando FP são problemáticos (ex.: diagnósticos médicos).
Recall (Revocação)	$\frac{TP}{TP+FN}$	Boa quando FN são problemáticos (ex.: detecção de fraudes).
F1-Score	$2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$	Boa para balancear precisão e recall.
Support	Número total de amostras por classe	Indica a quantidade de exemplos reais da classe.

ATENÇÃO PARA DADOS DESBALANCEADOS:

Vamos considerar um cenário de **fraude bancária**, onde **apenas 5% das transações são fraudulentas** (classe 1), e **95% são legítimas** (classe 0).

•950 exemplos da classe 0 (Negativo)

•50 exemplos da classe 1 (Positivo)

- **Acurácia:**

$$\frac{920 + 10}{1000} = 0.93 \quad (93\%)$$

O modelo fez as seguintes previsões:

Real / Previsto	0 (Previsto)	1 (Previsto)	Total
0 (Real)	920 (TN)	30 (FP)	950
1 (Real)	40 (FN)	10 (TP)	50

Agora calculamos as métricas:

Classe	Precision	Recall	F1-Score	Support
0 (Negativo)	$\frac{920}{920+40} = 0.96$	$\frac{920}{920+30} = 0.97$	0.965	950
1 (Positivo)	$\frac{10}{10+30} = 0.25$	$\frac{10}{10+40} = 0.20$	0.22	50
Média	0.605	0.585	0.592	-

🚨 **Problema detectado!**

- Apesar de a **acurácia parecer alta (93%)**, o modelo **fracassa** em identificar as fraudes.
- **Recall da classe 1 = 0.20**, ou seja, **o modelo detecta apenas 20% das fraudes!**
- **Precisão da classe 1 = 0.25**, indicando que **75% das transações classificadas como fraude são falsas alarmes.**

✅ **Conclusão:**

- A **acurácia engana** em problemas desbalanceados.
- **Recall e F1-score são mais importantes** para avaliar o modelo quando detectar a classe minoritária é crucial (como em fraudes e diagnósticos médicos).

Conclusões gerais

✅ **Se as classes forem balanceadas**, a acurácia pode ser uma boa métrica.

🚨 **Se houver desbalanceamento**, a acurácia pode ser **enganosa**, e é melhor focar em:

- **Precision** (se erros do tipo falso positivo forem mais problemáticos).
- **Recall** (se erros do tipo falso negativo forem mais perigosos, como em fraudes e diagnósticos médicos).
- **F1-score** (se precisarmos equilibrar precisão e recall).

📢 **Moral da história:** Nunca analise apenas a acurácia! **Olhe para todas as métricas, especialmente em problemas desbalanceados.** 🚀